

BIG DATA ET CLOUD COMPUTING

*THEME : Mise en place d'une pipeline
de données sur le cloud*

Membres du groupe :

Paul BALAFAI

Jean Luc BATABATI

Papa Amadou NIANG

Ahmadou NIASS

Samba SOW

Elèves Ingénieurs Statisticiens

Economistes


Professeur :

Mme Mously DIAW

*Lead ML Engineer | Experte IA
& MLOps*

Décembre 2025

Plan de la présentation





INTRODUCTION

CONTEXTE

- Digitalisation des marchés financiers → production continue de données boursières (prix, volumes, indices).
- Volumes massifs et croissance rapide des données financières.
- Les données mondiales sont passées de 64 ZB en 2020 à ~181 ZB en 2025 (IDC).
- Exploitation des données devenue essentielle pour l'analyse financière, la gestion des risques et la décision stratégique.




PROBLEMATIQUE

- Difficulté à traiter des données boursières volumineuses et historiques profonds.
- Besoin de fiabilité, de scalabilité et d'automatisation.
- Limites des solutions traditionnelles (serveurs locaux, traitements manuels).
- Question centrale : comment concevoir un pipeline batch efficace sur le cloud ?



OBJECTIFS

- Mettre en place un pipeline Big Data ETL pour données boursières.
- Assurer la collecte, le nettoyage, la transformation et le stockage des données.
- Garantir performance, robustesse et traçabilité.
- Faciliter l'exploitation analytique et la prise de décision.



I-CADRE CONCEPTUEL ET ENJEUX



BIG DATA

- *Ensemble de technologies permettant de traiter des données volumineuses, rapides et variées.*
- *Dimensions clés : Volume, Vitesse, Variété.*
- *Dans notre projet : gestion d'historiques boursiers massifs.*

- *Chaîne automatisée de traitement des données, de la source à l'analyse.*
- *Étapes : ingestion → transformation → stockage → exploitation.*
- *Dans notre projet : automatisation du flux boursier.*

PIPELINE DE DONNEES



ETL

- Extract : collecte des données (API, fichiers).
- Transform : nettoyage, formatage, calculs.
- Load : stockage dans le cloud.
- Pourquoi ETL : contrôle des données avant stockage.

Ingestion batch

- Collecte de données à intervalles réguliers.
- Adaptée aux données historiques.
- Dans notre projet : chargement quotidien des données boursières.

Gouvernance des données

- Ensemble des règles assurant la qualité, la traçabilité et la sécurité des données.
- Inclut : métadonnées, contrôle d'accès, qualité des données.
- Dans notre projet : fiabilité et cohérence des données financières.

Orchestration


- Pilotage et automatisation de l'exécution du pipeline
- Fonctions clés :
 - Planification des tâches
 - Gestion des dépendances
 - Redémarrage en cas d'échec
 - Supervision des workflows
- Dans notre projet : exécution automatique du pipeline ETL batch.



Enjeux économiques et technologique

Importance des données boursières

- Données clés pour :
 - l'analyse des marchés,
 - la gestion des risques,
 - la prise de décision économique.
- Adoption massive :
 - +95 % des banques mondiales utilisent des solutions Big Data (2025).
 - 85 % des banques américaines exploitent le Big Data pour optimiser décisions et processus.



Nécessité d'un traitement Big Data

Explosion des volumes de données financières :

- Données mondiales multipliées par plus de 30 entre 2010 et 2020.
- 64 zettaoctets en 2020, plus de 180 zettaoctets en 2025.
- Gestion d'historiques boursiers profonds et multi-sources.
- Besoin de performance, fiabilité et automatisation.



Limites des solutions traditionnelles

- Architectures locales peu scalables.
- Coûts élevés de maintenance.
- Faible automatisation des traitements.
- Difficultés à absorber la croissance des données

Apport du cloud computing

- Scalabilité et élasticité des ressources.
- Automatisation native des pipelines Big Data.
- Réduction des coûts d'infrastructure.
- Adoption croissante :
 - 60,5 % du marché Big Data financier basé sur le cloud.
 - 60 % des banques migrent ≥ 30 % de leurs workloads critiques vers le cloud (2025).

Enjeux économiques

- Marché mondial du cloud :
 - 676,3 Md USD en 2024 → 781,3 Md USD en 2025.
- Marché du cloud financier :
 - 152 Md USD en 2024, en forte croissance.
- Le cloud devient un levier de compétitivité et de résilience.



II- DESCRIPTION DES DONNÉES ET MÉTHODOLOGIE DE CONCEPTION DU PIPELINE



Description des données

Structure des données

Les données sont structurées en 12 colonnes incluant ticker, datetime, open, high, low, close, adj_close, volume et métadonnées.

➡ *Ticker : colonne des symboles uniques permettant d'identifier rapidement un titre financier*

➡ *Datetime : représente le temps exact de chaque observation (jour, heure, minute selon l'intervalle demandé)*

➡ *Open : Prix auquel l'actif s'échange au début de la période considérée*

➡ *High : Prix le plus élevé atteint par l'actif pendant la période considérée*

➡ *Low : Prix le plus bas atteint par l'actif pendant la période*

➡ *Close : Dernier prix enregistré pendant la période considérée*

➡ *Volume : mesure le nombre total de titres échangés pendant la période*

MÉTHODOLOGIE DE CONCEPTION DU PIPELINE (1/2)

1. Choix de la structure de la base de données

La base de données est divisée en 2 zones :

- **Zone Raw** : Stockage de données brutes
- **Zone Curated** : Stockage de données transformées

2. Implémentation du pipeline ETL

INGESTION : Avec l'API de Yahoo finance a travers le package python yfinance

- **TRANSFORMATION et CHARGEMENT** : implémenté via un service conteneurisé. les codes de transformation sont mis dans un docker contenant les codes de transformation et ensuite qui les stocke dans la Zone Curated de notre cloud.
- **Catalogage** (étape intermédiaire pour la visualisation) : Découverte et schématisation des données de la zone Curated pour faciliter un accès externe

MÉTHODOLOGIE DE CONCEPTION DU PIPELINE (2/2)

3. Gouvernance des données et Sécurité (IAM)

Gestion stricte des accès via des rôles et politiques IAM personnalisées : permissions centralisées (groupe yf-etl-user), contrôle fin au niveau des ressources (ARN), accès S3 limité aux zones curated et athena-results, exécution ECS/Fargate restreinte à une définition de tâche spécifique, et deny explicite empêchant toute suppression des données sensibles (zones Raw et Processed).


4. Validation finale et visualisation des données

La validation de bout en bout est assurée par l'exécution de requêtes SQL dans Athena, confirmant la cohérence entre les données stockées sur S3 et les schémas du catalogue Glue. La correction des anomalies de métadonnées au niveau du Data Catalog garantit la fiabilité des tables exposées. Ces données validées sont ensuite mises à disposition pour la visualisation et l'exploration analytique, via des outils de Business Intelligence et de data visualisation (tableaux de bord interactifs, analyses exploratoires) connectés à Athena/Glue.

The background is a deep blue gradient. In the lower half, there is a complex network of glowing blue nodes connected by thin, light blue lines, creating a web-like or molecular structure. Some nodes are brighter than others, and the lines vary in opacity. The overall effect is a sense of digital connectivity and data flow.

III- ARCHITECTURE GLOBALE DU PIPELINE

Flux de données automatisé



Ingestion et stockage structuré

Construction & Ingestion

AWS CodeBuild : CI/CD, récupération du code GitHub et build de l'image Docker avec dépendances.

Amazon ECS : Environnement d'exécution conteneurisé pour les scripts ETL Python.

Logique ETL : Maîtrise totale des traitements via scripts Python centralisés.

Data Lake S3

Zone Raw : Données brutes extraites, converties directement en format Parquet.

Zone Curated : Données nettoyées et raffinées.

Partitionnement : Organisation dynamique en sous-dossiers (intervalle-1-d, intervalle-1-h) pour optimiser les requêtes.

Catalogage, orchestration et visualisation

AWS Glue & Athena

Le Crawler scanne le dossier Curated pour mettre à jour le catalogue. Athena permet le requêtage SQL serverless direct sur les fichiers S3.

EventBridge

Orchestration temporelle via règles Cron. Déclenchement quotidien automatique à la clôture des marchés (16h00 NY).

Dashboard Dash

Application web interactive en Python. Connectée à Athena pour afficher les indicateurs financiers agrégés aux utilisateurs finaux.

Stratégie cloud : pourquoi AWS ?

Bien qu'Azure et GCP offrent des services équivalents, AWS a été sélectionné pour sa maturité sur le Data Lake et son intégration serverless fluide.

- Évolutivité & Coûts : Modèle Pay-as-you-go optimisé.
- Intégration ECS/Athena : Synergie entre conteneurs et analytique.
- Maîtrise ETL : Flexibilité totale du code Python.



IV- LIMITES, RISQUES ET ÉVOLUTIONS POTENTIELLES

The background is a deep blue gradient. In the lower half, there is a complex network of glowing blue nodes connected by thin, light blue lines, creating a web-like or molecular structure that spans the width of the image. Some nodes are brighter than others, and the lines have a slight glow.

Limites actuelles et risques

Données & Schéma

Granularité (Latence 24h) : Le traitement par lots empêche la vision temps réel des marchés.

Dérive du Schéma : Les changements de structure à la source peuvent casser le catalogue Glue et les requêtes Athena.

Performance & Ops

Calculs Côté Client : Moyennes mobiles calculées par Dash (Pandas) au lieu de l'ETL, alourdissant l'application.

Manque d'Observabilité : Absence de monitoring centralisé proactif pour les échecs de jobs.

Feuille de route et évolutions



Temps Réel

Migration vers Kinesis/Kafka pour l'ingestion continue.



Tests de Contrat

Validation auto du schéma dans CI/CD CodeBuild.



Optimisation ETL

Calculs indicateurs (PySpark) côté serveur.



Observabilité


Logs centralisés CloudWatch et alarmes proactives.

Vision architecture cible

Vers un écosystème réactif et robuste.

L'évolution vers une ingestion événementielle couplée à une validation stricte des données transformera le pipeline actuel en une solution de streaming quasi temps réel.

Cette modernisation garantira non seulement la fraîcheur des données financières mais aussi la stabilité opérationnelle grâce à une supervision proactive.



Conclusion

Ce projet a permis de concevoir une pipeline de données cloud automatisée et scalable dédiée au traitement de données financières. L'architecture mise en place, basée sur un Data Lake sur AWS, couvre l'ensemble du cycle de vie de la donnée, de l'ingestion batch à l'analyse, en répondant aux contraintes spécifiques des données boursières telles que la volatilité, la temporalité et la qualité des données.

La pipeline permet de transformer des données brutes en informations analytiques exploitables grâce à des traitements automatisés, des requêtes SQL serverless et un dashboard interactif développé avec Dash. Ce projet met en évidence le rôle stratégique du cloud computing et du data engineering dans la valorisation des données financières et l'aide à la décision, tout en offrant une architecture évolutive adaptée aux besoins futurs.